HOIE 과학을 위한 RIZ 기개의

5주차. 데이터탐색



이혜선 교수

포항공과대학교 산업경영공학과



5주차. 데이터탐색

1차시 데이터 다루기(결합, 분할)

2차시 데이터탐색과 기술통계치

3차시 데이터시각화를 이용한 데이터탐색



데이터시각화를 이용한 데이터탐색



● 데이터 기술통계치요약

☑ stud_math 데이터: 포루투칼의 고등학생 수학성적(stud_math_desc.doc 참고)

school: 학교이름 (GP, MS)

sex : 성별 (F, M)

age : 나이 (15-22)

address : 주소 (Urban:도심, Rural:외곽)

Medu : 엄마교육수준

famsize : 가족수 (LE3 :≤3, GT3: >3)

Fedu: 아빠교육수준

traveltime: 통학시간: 1(15분이하),2,3,4(1시간이상)

Dalc : 음주(1-5)

studytime: 주중공부시간: 1(<2시간), 2(2-5시간), 3(5-10시간), 4(>10시간)

health : 건강상태

(1(매우나쁨)-5(매우좋음))

activties : 방과후활동(yes, no)

romantic: 이성교제여부(yes, no)

nursery:유치원다녔는지여부(yes,no)

soout : 친구들과 외출 (1-5)

internet : 집에서 인터넷사용(yes,no)

absences : 학교결석 (0-93)

타겟변수: G3(최종성적, 0-20), G2(2학년), G1(1학년)

Attribute Information:

Attributes for both student-maticsv (Mathicourse) and student-poricev (Portuguese language course) datasets

1 school - student's school (binary: 'GP' - Gabriel Pereira or 'MS' - Mousinho da Silveira)

2 sex - student's sex (binary: F' - female or M' - male)

3 age - student's age (numeric: from 15 to 22)

4 address - student's home address type (binary: "U" - urban or "R" - rural)

5 famsize - family size (binary: "LE3" - less or equal to 3 or "GT3" - greater than 3).

6 Pstatus - parent's cohabitation status (binary: 'T' - living together or 'A' - apart)

7 Medu - mother's education (numeri: 0 - none, 1 - primary education (4th grade), 2 &F 5th to 9th grade, 3 &F secondary educino (4th grade), 2 &F 5th to 9th grade, 3 &F 5th to 9th grade), 3 &F 5th to 9th grade, 3 &F 5th to 9th grade

10 Fjob - father's job (nominal: 'beacher', 'health' care related, civil 'services' (e.g. administrative or police), 'at, home' or 'other')

11 reason - reason to choose this school (nominal: close to 'home', school 'reputation', 'course' preference or 'other')
12 quardian - student's quardian (nominal: 'mother', Tather' or 'other')

13 traveltime - home to school travel time (numeric: 1 - <15 min; 2 - 15 to 30 min; 3 - 30 min; to 1 hour; or 4 ->1 hour)

14 studytime - weekly study time (numeric: 1 - <2 hours, 2 - 2 to 5 hours, 3 - 5 to 10 hours, or 4 -> 10 hours)

15 failures - number of past class failures (numeric: n if 1<=n<3, else 4)

16 schoolsup - extra educational support (binary: yes or no) 17 famsup - family educational support (binary: yes or no)

18 paid - extra paid classes within the course subject (Math or Portuguese) (binary, yes or no)

19 activities - extra-comicular activities (binary: yes or no)

20 nursery - attended nursery school (binary: yes or no) 21 higher - wants to take higher education (binary: yes or no)

22 internet - internet access at home (binary, yes or no)

23 romantic - with a romantic relationship (binary yes or no)

24 famrel - quality of family relationships (numeric: from 1 - very bad to 5 - excellent)

25 freetime - free time after school (numeric: from 1 - very low to 5 - very high)

26 goout - going out with friends (numeric: from 1 - very low to 5 - very high)

27 Dalc - workday alcohol consumption (numeric: from 1 - very low to 5 - very high)

28 Walic - weekend alcohol consumption (numeric: from 1 - very low to 5 - very high)

29 health - current health status (numeric, from 1 - very bad to 5 - very good)

30 absences - number of school absences (numeric: from 0 to 93)

these grades are related with the course subject, Math or Portuguese:

31 G1 - first period grade (numeric: from 0 to 20)

31 G2 - second period grade (numeric: from 0 to 20)

32 G3 - final grade (numeric: from 0 to 20, output target)


데이터시각화를 이용한 데이터탐색

○ 그래프를 이용한 데이터탐색

☑ 히스토그램 (1학년, 2학년, 3학년 성적의 분포)

```
# Graphical analysis
library(dplyr)
# set working directory
setwd("D:/tempstore/moocr")
### student math grade data ####
stud<-read.csv("stud_math.csv")
head(stud)
dim(stud)
str(stud)
attach(stud)
# 1. histogram with color and title, legend
par(mfrow=c(2,2))
hist(G1, breaks = 10, col = "lightblue", main="Histogram of Grade 1"
hist(G2, breaks = 10, col = "green", main="Histogram of Grade 2" )
hist(G3, breaks = 10, col = "coral", main="Histogram of Grade 3")
```





5주차 3차시


데이터시각화를 이용한 데이터탐색

○ 그래프를 이용한 데이터탐색

☑ 상자그림 (거주지역에 따른 G3, 통학시간에 따른 G3)

```
# 2. boxplot
par(mfrow=c(1,2))
boxplot(G3~address, boxwex = 0.5, col = c("yellow", "coral"), main="G3 by
boxplot(G3~traveltime, boxwex = 0.5, col = c("red", "orange", "yellow", "gree
```

- (1) 도심지역 학생들 성적이 외곽지역 학생들보다 높다
- (2) 통학시간이 짧은(15분 이내)의 학생들의 성적이 더 높다



5주차 3차시

데이터시각화를 이용한 데이터탐색


○ 그래프를 이용한 데이터탐색


☑ 상자그림 (자유시간에 따른 G3, 공부시간에 따른 G3)

```
# boxplot
par(mfrow=c(1,2))
# academic achievement by freetime
# 1 - very low to 5 - very high
boxplot(G3~freetime, boxwex = 0.5, col = c("yellow", "green", "blue
# academic achievement by studytime
# 1 - <2 hours, 2 - 2 to 5 hours, 3 - 5 to 10 hours, or 4 - >10 hou
boxplot(G3~studytime, boxwex = 0.5, col = c("yellow", "blue", "grey")
```

(1) 방과후 자유시간에 따른 G3의 차이 : 자유시간 이 적은 편(low)이라고 응답한 학생들의 성적이 가장 높은데, 다른 요인과 혼합되어 그럴 수 있음..

(2) 주중공부시간이 5시간이상 (3: 5-10시간, 4: 10 시간이상)인 학생들의 성적이 높은 편





5주차 3차시 > 데이터시각화를 이용한 데이터탐색

● 그래프를 이용한 데이터탐색

```
# ggplot2 package
library(ggplot2)
# 3. scatterplot for G1 and G3 by sex
ggplot(stud, aes(x=G1, y=G3, color=sex, shape=sex)) + geom_point(size=4)
ggplot(stud, aes(x=G1, y=G3, color=rpmantic, shape=romantic)) + geom_point(size=4
```


성별이나 연애 경험에 따른 차이는 없음


5주차 3차시 데이터시각화를 이용한 데이터탐색



○ 그래프를 이용한 데이터탐색

☑ G3=0인 데이터 (n=38명)





e_insr =	0] 800,1/	R = 10.	166,2 R =	3m s st		14.4	E # 19 1605,2.81*		· > =D			
internet	romantic		freetine	geout	Date	Walte	beatch	absences	61	GŽ	G#	
yes.	80	- 3	3	3	. 1	2	4	a	.7	4	0	k
yes	yes	- 4	- 2	2	2	- 2	- 1	a	12	0	0	
yes	Aas	- 4		3	. 1	- 2	- 4	0	8	0	0	
110	yes		3	3			9	0	9	0	0	
yes .	yes	- 4	- 3	3	- 1	- 1	- 8	0	11	0	D	Į,
no.	no	- 5	- 4	- 5	2	4	- 1	0	10	0	D	Ħ
yes	yes	. 4	. 3	2		1		0	4	0	0	
yes	HQ:	- 2	. 2	- 2	- 1	- 1	3	0	2	9	0	
VIEW	no	- 5	. 4	- 5	- 1	- 2	- 1	0	\$	0	Ω	
yes	no	3	- 1	2	- 1	- 1	- 3	α		7	0	
yes	yes	- 3		2	2	- 1	9	0	2	- 6	U	
yes	yes	- 2	3	- 5	5		- 4	0	6	- 5	0	
yes	yes	4	2	- 4	- 1	-11	4	0	1	0	0	
yes	yes	3	3	- 2	2	2	5	0	7		D	
no	HO		4	4	2	+	- 19	0	. 9	0	D	
yes	No:	- 8	1.3	5	1	- 1	4	0	6	7.	D	
Ver.	110	- 3	4	5	2	4	3	a	ė	5	0	
yex	yes				. 1	- 1	3	Ø.		7	0	
HO:	yes		3	4	1	1	1.5	0	- 6	1	0	

5주차 3차시 에이터시각화를 이용한 데이터탐색

● 그래프를 이용한 데이터탐색

막대그림 (ggplot2 패키지의 ggplot이용)




5주차 3차시 에이터시각화를 이용한 데이터탐색

○ 그래프를 이용한 데이터탐색

```
# 5. pariwise plot
# new variable lists
vars1<-c("G1", "G2", "G3")
# pariwise plot
pairs(stud[vars1], main = "Student Math Data",
      pch = 21, bg = c ("red", "green3"))
```

- (1) G1, G2, G3간의 상관성은 매우 높다
- (2) 성별 간 차이는 없다



5주차 3차시 에이터시각화를 이용한 데이터탐색

● 데이터의 정규성검정


☑ 정규확률도 (Normal Q-Q plot) : 데이터가 정규분포하는가?

```
# multiple plot (2 by 2)
par(mfrow=c(2,2))
#Quantile plot
qqnorm(G1)
qqline(G1, col = 2, cex=7)
qqnorm(G2)
qqline(G2, col = 2, cex=7)
ggnorm(G3)
qqline(G3, col = 2, cex=7)
```




qqline의 디폴트는 정규분포의 1사분위, 3사분위를 직선

qqline(y, distribution = qqnorm, probs = c(0.25, 0.75))



데이터시각화를 이용한 데이터탐색

- 데이터의 정규성검정
- ☑ 정규분포 적합성검정 : 데이터가 정규분포 하는지에 대한 검정
 - 🤰 (1) Shapiro-Wilks검정



🤰 (2) Anderson-Darling검정 (추가패키지 필요)

```
#Anderson-Darling test require installing package "nortest"
install.packages('nortest')
library(nortest)
ad.test(G3)

Anderson-Darling normality test

data: G3
A = 8.3032, p-value < 2.2e-16
```