日の日子学会会で

11주차. 의사결정나무와 랜덤포레스트



이혜선 교수

포항공과대학교 산업경영공학과



11주차. 의사결정나무와 랜덤포레스트

1차시 의사결정나무 I


2차시 의사결정나무 II

3차시 랜덤포레스트



POSTPCH

- 의사결정나무(Decision Tree)
- ☑ 의사결정나무(Decision Tree)
 - 기계학습 중 하나, 의사결정 규칙을 나무 형태로 분류해 나가는 분석 기법



- ▶ 분석 과정이 직관적이고 이해하기 쉬움
- ❖ 연속형/범주형 변수 모두 사용할 수 있음
- ★ 분지 규칙은 불순도를 최소화시킴

범주들이 섞여있는 정도



● 의사결정나무(Decision Tree)

Step1

tree 형성(Growing tree)

Step1

tree 가지치기(Pruning tree)

Step1

최적 tree로 분류(Classification)



- 의사결정나무(Decision Tree)
- ☑ 의사결정나무 실행 패키지 : tree(그 외 rpart, party 패키지)

```
# lec11_1_tree.R
# Decision tree
# use package "tree"

#decision tree packages download
install.packages("tree")
library(tree)

#package for confusion matrix
#install.packages("caret")
library(caret)
}
```

tree: 의사결정나무 수행을 위한 패키지

caret: confusionMatrix 사용을 위한 패키지



● **의사결정나무**(Decision Tree)

☑ iris 데이터(iris.csv)

	innut	변수(독립법	벼스)		Out	put변수(종속변수, 타겟변수)
•	mpat		<u>-</u> /		out	pute+(8 - e+, -1 x e+)
	А	В	С	D	E	1
	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species	
	5.1	3.5	1.4	0.2	setosa	
	4.9	3	1.4	0.2	setosa	
	4.7	3.2	1.3	0.2	setosa	
	4.6	3.1	1.5	0.2	setosa	
	5	3.6	1.4	0.2	setosa	디게벼스(//)
	5.4	3.9	1.7	0.4	setosa	타겟변수(y) :
	4.6	3.4	1.4	0.3	setosa	
	5	3.4	1.5	0.2	setosa	The state of the s
	4.4	2.9	1.4	0.2	setosa	TO THE RESERVE OF
	4.9	3.1	1.5	0.1	setosa	
	5.4	3.7	1.5	0.2	setosa	
	4.8	3.4	1.6	0.2	setosa	
	4.8	3	1.4	0.1	setosa	

타겟변수(y): setosa, versicolor, virginica



Iris setosa

Iris versicolor Iris virginica

● 의사결정나무(Decision Tree)

☑ Iris 데이터(학습데이터와 검증데이터의 분할)

```
# set working directory
setwd("D:/tempstore/moocr")
# read csv file
iris<-read.csv("iris.csv", stringsAsFactors = TRUE)</pre>
attach(iris)
# training (n=100)/ test data(n=50)
                                                         데이터분할
set.seed(1000)
N<-nrow(iris)
                                                         (학습데이터 2/3, 검증데이터 1/3)
tr.idx<-sample(1:N, size=N*2/3, replace=FALSE)
# split train data and test data
                                                         train (100개의 데이터)
train<-iris[tr.idx,]
test<-iris[-tr.idx,]
                                                         test (50개의 데이터)
#aim(train)
#dim(test)
```



● **의사결정나무**(Decision Tree)

☑ tree패키지에 있는 tree함수

help("tree")

tree {tree} R Documentation

Fit a Classification or Regression Tree

Description

A tree is grown by binary recursive partitioning using the response in the specified formula and choosing splits from the terms of the right-hand-side.

Usage

```
tree(formula, data, weights, subset,
                          control = tree.control(nobs, ...),
          = FALSE, x = FALSE, y = TRUE, wts = TRUE, ...)
```

Arguments

formula	A formula expression. The left-hand-side (response) should be either a numerical vector when a regression tree will be fitted or a factor, when a classification tree is produced. The right-hand-side should be a series of numeric or factor variables separated by +; there should be no interaction terms. Both . and – are allowed: regression trees can have offset terms.	
data	A data frame in which to preferentially interpret ${\tt formula}, {\tt weights}$ and ${\tt subset}.$	
weights	Vector of non-negative observational weights; fractional weights are	

An expression specifying the subset of cases to be used. subset

● 의사결정나무(Decision Tree)

☑ 의사결정나무 함수 : tree(종속변수~x1+x2+x3+x4, data=)

Step1


```
# step1 : growing tree
treemod<-tree(Species~., data=train)
                                                             Petal.Length < 2.45
treemod
plot(treemod)
text(treemod,cex=1.5)
                                                                        Petal.Width < 1.75
                                                       setosa
 ▶ plot(treemod) : 의사결정나무 분지를 그림으로 표현
                                                                Petal.Width < 1.45
                                                                                Petal.Length < 4.95
  ▲ cex : 폰트 사이즈
                                                                                virginica
                                                                                        virginica
                                                               versicolor
                                                                       versicolor
```

- 의사결정나무(Decision Tree)
- ☑ 학습데이터의 tree결과
- ☑ tree의 결과(*는 터미널노드) : 마디 6에서는 더 이상 분지할 필요 없음

```
node), split, n, deviance, yval, (yprob)
    denotes terminal node
1) root 100 219.500 versicolor ( 0.34000 0.35000 0.31000 )
  3) Petal.Length > 2.45 66 91.250 versicolor ( 0.00000 0.53030 0.46970 )


    Petal.Width < 1.75 37 20.820 versicolor ( 0.00000 0.91892 0.08108 )</li>


   13) Petal.Width > 1.45 11 12.890 versicolor ( 0.00000 0.72727 0.27273 ) *
   7) Petal.Width > 1.75 29 8.700 virginica ( 0.00000 0.03448 0.96552 )
   14) Petal.Length < 4.95 5 5.004 virginica ( 0.00000 0.20000 0.80000 ) *
```




Step2

- **의사결정나무**(Decision Tree)
- ☑ 최적tree모형을 위한 가지치기(pruning) : cv.tree(tree모형결과, FUN=)
- ☑ 아래 결과에서 교차검증오차(deviance)의 값이 최소가 되는 노드 수를 선택











- 의사결정나무(Decision Tree)
- ☑ pruning(가지치기) : cv.tree함수를 이용하여 최적 터미널노드를 탐색






● 의사결정나무(Decision Tree)





- 의사결정나무(Decision Tree)
- ☑ pruning(가지치기) 전과 후의 tree





● 의사결정나무(Decision Tree)

☑ 의사결정나무결과 정확도 : test data에 대한 정확도

Step3

```
# step 3: classify test data
treepred<-predict(prune.trees,test,type='class')
# classification accuracy
confusionMatrix(treepred,test$Species)
                                      Confusion Matrix and Statistics
                                                      실제범주
                                         예측범주
                                                   Reference
                                      Prediction
                                                   setosa versicolor virginica
                                        setosa
                                                         16
                                        versicolor
                                                                     15
                                        virginica
                                      Overall Statistics
                                                       Accuracy: 0.96
```