RIOIEI과학을위한 RIFTHU

13주차. 연관규칙과 로지스틱모형



이혜선 교수

포항공과대학교 산업경영공학과



13주차. 연관규칙과 로지스틱모형

1차시 연관규칙 I

2차시 연관규칙 II

3차시 로지스틱 회귀모형



● 로지스틱 회귀모형

Y: Remiss (0, 1)

6 explanatory variables: risk factor related cancer remission(cell, smear, infill, li, blast, temp)

remiss	cell	smear	infil	li	blast	temp
1	1 0.8		0.66	1.9	1.1	0.996
1	0.9	0.36	0.32	1.4	0.74	0.992
0	0.8	0.88	0.7	8.0	0.176	0.982
0	1	0.87	0.87	0.7	1.053	0.986
1	0.9	0.75	0.68	1.3	0.519	0.98
0	1	0.65	0.65	0.6	0.519	0.982
1	0.95	0.97	0.92	1	1.23	0.992
0	0.95	0.87	0.83	1.9	1.354	1.02

Remission data (Lee, 1974)

							V	
+	remiss	cell	smear	infil	li	blast	temp	t3\$fitted.values
_	1	8.0	0.83	0.66	1.9	1.1	0.996	0.722648915
	1	0.9	0.36	0.32	1.4	0.74	0.992	0.578739122
	0	8.0	0.88	0.7	8.0	0.176	0.982	0.104598953
	0	1	0.87	0.87	0.7	1.053	0.986	0.282577342
	1	0.9	0.75	0.68	1.3	0.519	0.98	0.714180403
	0	1	0.65	0.65	0.6	0.519	0.982	0.270886837
	1	0.95	0.97	0.92	1	1,23	0.992	0,321555392

● 로지스틱 회귀모형

☑ 로지스틱 회귀분석(logistic regression)은 종속변수가 범주형인 경우 타겟변수가 2개의 범주(양성/음성, 불량/양품 등) 혹은 3개 이상의 범주일때 사용 3개 범주 이상의 경우 서열형 데이터(ordinal data), 명목형 데이터(nominal data)에 따라 다른 모형이 사용됨

$$logit(p) = ln(\frac{p}{1-p})$$
 $logit(p) = \beta_0 + \beta_1 x$

 \mathbf{V} 회귀계수 $\mathbf{\beta}_1$ 의 의미는 선형회귀 모형에서 와는 다름 β_1 는 X가 한 단위 증가할 때 logit(p), 즉 승산비의 로그값의 증가분을 말하므로 승산비가 e^{β_1} 배로 증가함을 의미함



● 로지스틱 회귀모형

☑ Y 가 (0/1, cancer/no cancer, present/absent) 등의 값을 취하는 경우, 다음과 같은 로지스틱 함수가 독립변수들과 Y간의 관계를 설명하기 위해 사용됨

$$f(y) = \frac{1}{1 + e^{-y}}$$

✓ 로짓모형은 Y= (0,1)

Logistic function

1.0

0.8

$$f(y)$$

0.4

0.2

0.0

0.0

0.0

0.5

10

$$P_{i} = \Pr\{Y_{i} = 1 \mid X_{1}, ..., X_{k}\} \qquad P_{i} = \frac{1}{1 + e[-(\beta_{0} + \beta_{1}X_{1} + ... + \beta_{k}X_{k})]}$$

$$\overset{\hat{O}R}{OR}_{X_{1}=1 \text{ vs } X_{1}=0} = \frac{\overset{\hat{O}dds}{Odds}(Y=1 \mid X_{1}=1, X_{2}, ..., X_{k})}{\overset{\hat{O}dds}{Odds}(Y=1 \mid X_{1}=0, X_{2}, ..., X_{k})} = \frac{e^{\hat{\beta}_{0}+\hat{\beta}_{1}+\hat{\beta}_{2}X_{2}+...\hat{\beta}_{i}, X_{k}}}{e^{\hat{\beta}_{0}+\hat{\beta}_{2}X_{2}+...\hat{\beta}_{i}, X_{k}}} = \overset{\hat{\Phi}_{0}}{e^{\hat{\beta}_{0}+\hat{\beta}_{2}X_{2}+...\hat{\beta}_{i}, X_{k}}} = \overset{\hat{\Phi}_{0}}{e^{\hat{\beta}_{0}+\hat{\beta}_{1}X_{2}+...\hat{\beta}_{i}, X_{k}}} = \overset{\hat{\Phi}_{0}}{e^{\hat{\beta$$

회귀계수의 해석

●로지스틱 회귀모형 - 예제

☑ 로지스틱 회귀모형 : y는 binomial variable, logit function 선택

```
#logistic regression (full model)
tl<-qlm(remiss-cell+smear+infil+li+blast+temp, data=re,family=binomial(logit)
summary(t1)
cor(re)
> tl<-glm(remiss-cell+smear+infil+li+blast+temp, data=re.family=binomial(logit))
> summary(t1)
glm(formula = remiss - cell + smear + infil + li + blast + temp.
   family = binomial(logit), data = re)
Deviance Residuals:
                   Median
-1.95165 -0.66491 -0.04372 0.74304
coefficients:
                                                                          check p-value
           Estimate Std. Error z value Pr(>|z|)
(Intercept) 58.0385
                     71.2364
                               0.815
                                      0.4152
                                                                          and correlation
           24.6615
                     47.8377
                               0.516
                                      0.6062
snear
                               0.333
                                      0.7392
infil
          -19.6013
                     61.6815
                              -0.318
                                      0.7507
15
                      2.3371
                              1.667
                                      0.0955
            0.1511
                      2.2786
                              0.066
                                      0.9471
                             -1.294
           -87.4339
                     67.5735
                                      0.1957
temp
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for binomial family taken to be 1)
   Null deviance: 34,372 on 26 degrees of freedom
Residual deviance: 21.751 on 20 degrees of freedom
AIC: 35,751
```

```
> cor(re)
           remiss
                       cell
                                              infil
                                 smear
                             0.1994882
remiss 1.0000000 0.2645288
                                        0.26399695
cell
        0.2645288 1.0000000
                             0.2917881
                                        0.60707674
        0.1994882 0.2917881
                             1.0000000
smear
infil
        0.2639970 0.6070767
        0.5419818 0.1902352
                            0.3174573
       0.3613662 0.4387766
                             0.6113205
       -0.1562395 0.1081586 -0.1124464 -0.04444844
                       blast
remiss 0.54198183 0.3613662 -0.15623948
cell
        0.19023518 0.4387766 0.10815860
smear
       0.31745727 0.6113205 -0.11244639
infil
       0.32114358 0.6944519 -0.04444844
        1.00000000 0.6036873 -0.05477238
       0.60368727 1.0000000
blast
                             0.21639325
       -0.05477238 0.2163933 1.00000000
```

blast. infill 제거 후 다시 수행

●로지스틱 회귀모형 - 예제

☑ 로지스틱 회귀모형의 평가척도 : -2Log(Deviance), AIC, likelihood ratio test(G²)

```
> t2<-glm(remiss~cell+smear+li+temp, data=re,family=binomial(logit))
> summary(t2)
call:
glm(formula = remiss ~ cell + smear + li + temp, family = binomial(logit),
    data = re)
Deviance Residuals:
     Min
                     Median
-1.87933 -0.66813 -0.07052 0.78408 1.72472
Coefficients:
           Estimate Std. Error z value Pr(>|z|)
                       58.7634
(Intercept) 70,0994
                               1.193 0.2329
             9.8507
                    7.8263
                               1.259 0.2082
cell
             0.9124
                    2,9600
                                0.308
                                      0.7579
smear
                               2.150 0.0316 #
                    1.8167
            3.9052
           -85.4447
                    64.2143 -1.331 0.1833
temp
Signif, codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for binomial family taken to be 1)
    Null deviance: 34.372 on 26 degrees of freedom
Residual deviance: 21.858 on 22 degrees of freedom
AIC: 31.858
```

●로지스틱 회귀모형 - 예제

```
> t3<-glm(remiss~cell+li+temp, data=re,family=binomia
> summary(t3)
call:
glm(formula = remiss ~ cell + li + temp, family = bin
    data = re)
Deviance Residuals:
                      Median
-2.02043 -0.66313 -0.08323
                               0.81282
Coefficients:
            Estimate Std. Error z value
(Intercept)
              67.634
                         56.888
                                  1.189
                                          0.2345
cell
               9.652
                                  1.245
                                          0.2130
                          7.751
11
                          1.778
                                  2.175
                                          0.0297
                         61.712
                                 -1.330
                                          0.1835
temp
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.'
(Dispersion parameter for binomial family taken to be
    Null deviance: 34.372 on 26 degrees of freedom
Residual deviance: 21.953 on 23 degrees of freedom
AIC: 29.953
```

Logistic equation

$$logit(p) = 67.63 + 9.65 Cell + 3.87 Li - 82.07 Temp$$

- 2 $\rho^{-(67.63+9.65Cell+3.87Li-82.07Temp)}$ $1 + \rho^{-(67.63+9.65Cell+3.87Li-82.07Temp)}$
- 3 overall significant
- 47.79 li 1단위 증가하면 remission 될 확률 exp(3.867)=47.79

앞의 모형(smear 포함, AIC=31.86)보다 AIC값이 낮음



- ●로지스틱 회귀모형 예제
- ☑ 주어진 데이터에 대한 로지스틱모형 확률값 계산 예제
 - ▶ 추정회귀식 logit(P)에서 <u>Cell=1, Li=1.2, Temp=.99</u>이면,

$$logit(p) = 67.63 + 9.65 * 1 + 3.87 * 1.2 - 82.07 * .99$$

$$p = \frac{\exp(0.68)}{\exp(0.68) + 1} = .6637$$

즉 remission 될 확률은 0.6637.

=> 임계치 (1과 0으로 할당하는)에 따라 이 관측치는 1 혹은 0으로 분류됨.

●로지스틱 회귀모형 - 예제

☑ 예측확률값 출력 : 원래 데이터 + 예측확률값

```
# output data with predicted probability
dat1_pred<-cbind(re,t3$fitted.values)</pre>
write.table(dat1_pred,file="dat1_pred.csv", row.names=FALSE, sep=",", na=" ")
```

remiss	cell	smear	infil	li	blast	temp	t3\$fitted.values
1	0.8	0.83	0.66	1.9	1.1	0.996	0.722648915
1	0.9	0.36	0.32	1.4	0.74	0.992	0.578739122
0	0.8	0.88	0.7	0.8	0.176	0.982	0.104598953
0	1	0.87	0.87	0.7	1.053	0.986	0.282577342
1	0.9	0.75	0.68	1.3	0.519	0.98	0.714180403
0	1	0.65	0.65	0.6	0.519	0.982	0.270886837
1	0.95	0.97	0.92	1	1.23	0.992	0.321555392
0	0.95	0.87	0.83	1.9	1.354	1.02	0.607231948
0	1	0.45	0.45	0.8	0.322	0.999	0.166316409